

Agente MCTS para Connect-4: diseño, evaluación empírica y limitaciones

Fermin Escalona | Fundamentos de Inteligencia Artificial

1. Idea principal y diferenciación frente al grupo

El agente se basa exclusivamente en **Monte Carlo Tree Search (MCTS) puro con UCB1**, sin entrenamiento offline ni redes de valor. Cada turno construye un árbol de búsqueda desde cero usando el presupuesto temporal disponible, complementado con (i) **reflejos tácticos en la raíz** —si existe una victoria inmediata se ejecuta sin simular, y si una acción del rival amenaza con victoria al turno siguiente se filtra de las acciones legales— y (ii) una gestión del presupuesto global de 60 s con margen de seguridad. Esta filosofía contrasta directamente con los dos enfoques principales del resto del grupo:

Eje	Comp. 1: TBOPI + Q-table self-play	Comp. 2: FVMC tabular + heurísticas	Este agente: MCTS+UCB1 online
Conocimiento	Q-table global <i>preentrenada</i> offline; depende de qué cubrió el self-play	Tabla $q(s, a)$ aprendida sobre las trayectorias visitadas	100 % online ; sin pretraining ni dependencia del pasado
Estructura de búsqueda	Búsqueda local tipo bandits desde la raíz (sin árbol profundo)	Acumulación tabular sobre estados-acción visitados	Árbol focalizado por UCB1 que profundiza en las ramas prometedoras
Visión táctica	Limitada: no proyecta secuencias largas de turnos alternos	Limitada por la cobertura de la tabla	Anticipa secuencias completas (<i>alternating Markov games</i>)
Selección final	UCB sobre Q precalculada	Acción con mayor q (<i>max-child greedy</i>)	Acción más visitada (robustez), con desempate por Q/N

Cuadro 1: Comparación conceptual con los enfoques del grupo.

Las ventajas estructurales de esta elección son tres: (i) no se arrastra ruido de exploración pasada —la Q-table del Compañero. 1 puede contener datos sesgados sobre jugadas raras o trampas que el self-play no cubrió, y la tabla q del Compañero. 2 sufre la *maldición de la dimensionalidad* (Connect-4 tiene miles de millones de estados, dejando la mayoría de celdas con $N = 1$ y valores estadísticamente no confiables); (ii) el árbol profundo permite ver jaques y victorias forzadas a 5–6 turnos, algo fuera del alcance de una búsqueda local; (iii) la decisión final por *robustez* (nodo más visitado) es menos vulnerable a un Q alto producto del azar con pocas simulaciones que la regla *max-q greedy* del Comp. 2.


Se desarrollaron dos versiones del mismo núcleo MCTS:

- **Head** (versión base): MCTS+UCB1 puro, reflejos tácticos en la raíz, *rollout completamente aleatorio* hasta estado terminal y presupuesto fijo por turno.
- **Eyes** (versión mejorada): añade (a) *presupuesto adaptativo* ajustado por fase del juego, factor de ramificación y dominancia del mejor hijo tras una pasada exploratoria de 0.08 s; (b) *rollout híbrido* que detecta victorias inmediatas y bloqueos forzosos durante la simulación; (c) margen de seguridad ampliado sobre el límite global.


Enlace al código final: <https://github.com/rafaelsava/Connect4RL/tree/Policy-Fermin>

2. Protocolo experimental

Se evaluó el rendimiento variando dos ejes: el **presupuesto por turno** ($\text{TURN_TIME_LIMIT} \in \{0.10, 0.20, 0.35, 0.50\}$ s) y el **oponente** (Random, versión rival entre Head y Eyes, y self-play del agente mejorado). Cada condición se midió con 10 partidas reales y jugador inicial balanceado para neutralizar la ventaja del primer movimiento.



(a) Tasa de victorias contra Random por presupuesto.




(b) Victorias promedio (sobre 10) frente a Random.


Figura 1: Evaluación contra oponente aleatorio uniforme. Ambas versiones saturan el criterio mínimo del 85 % en todos los presupuestos.

3. Análisis de resultados

Frente a Random (Figs. 1a–1b). Ambas versiones obtienen 100 % de victorias (10/10) en los cuatro presupuestos. Random resulta ser un techo poco informativo: los reflejos tácticos en la raíz bastan para cerrar partidas y el MCTS opera muy por encima del umbral exigido. *Este oponente no permite discriminar entre Head y Eyes*, lo que motiva los siguientes experimentos.



(a) Enfrentamiento directo Head (Base) vs. Eyes (Mejorado).



(b) Self-play de Eyes: dos instancias idénticas.

Figura 2: Evaluaciones discriminativas: enfrentamiento entre versiones y control de simetría mediante self-play.

Enfrentamiento directo (Fig. 2a). El resultado es contraintuitivo: la versión base **Head supera a Eyes in 3 de 4 presupuestos** (50/40/10 a 0.10s, 60/40 a 0.20s, 70/30 a 0.50s; empate técnico 50/50 a 0.35s). La ventaja además *se acentúa con presupuestos mayores*, justo donde se esperaba que las mejoras de Eyes rindieran más.

Self-play de Eyes (Fig. 2b). Como control de simetría, dos instancias idénticas deberían tender al 50/50. En cambio, Rol B gana entre 60 % y 70 % en 3 de 4 presupuestos. Esto evidencia que las decisiones de Eyes son *sensibles al orden de exploración del árbol y al ruido del rollout heurístico*, generando alta varianza incluso bajo condiciones perfectamente simétricas.

Diagnóstico. Las dos modificaciones de Eyes parecen hacerle daño: (a) el *rollout híbrido* reduce la diversidad de simulaciones y sesga los estimados hacia trayectorias muy cortas y tácticas, que no representan el verdadero valor de la posición; (b) la *gestión dinámica de tiempo* a veces recorta el presupuesto cuando la pasada exploratoria muestra una dominancia engañosa, regalando tiempo que Head sí usa para profundizar. En este dominio, el rollout aleatorio puro resulta ser un estimador *insesgado* más robusto que uno heurístico parcial.

4. Conclusiones

El experimento desmiente la hipótesis intuitiva de que añadir heurísticas tácticas al rollout y un presupuesto adaptativo mejoran MCTS automáticamente. **Más cómputo aleatorio gana a menos cómputo dirigido** cuando el sesgo del rollout supera el ahorro de tiempo. El rendimiento del agente no es una propiedad atómica: depende del presupuesto temporal, del tipo de rollout, del oponente (Random no discrimina; el rival Head sí) y de la dominancia de la posición. La versión recomendada como final es **Head**, por ser empíricamente superior en enfrentamiento directo y por presentar menor varianza.

5. Propuestas de mejora futura y trabajo futuro

Para elevar el desempeño competitivo del paradigma en línea sin incurrir en los sesgos perjudiciales observados en el agente **Eyes**, se proponen tres líneas de desarrollo tecnológico y optimización conceptual:

5.1. 1. Integración de Redes Neuronales Convolucionales (Enfoque AlphaZero Ligero)

Para solucionar el problema del costo computacional en las simulaciones, se plantea sustituir los rollouts aleatorios por un modelo de Aprendizaje Profundo. Se propone entrenar una red neuronal mediante auto-juego (*Self-Play*) que aprenda a reconocer patrones visuales y geométricos en el tablero. Esta red aportará dos componentes clave:

- **Guía de Expansión (Política):** En lugar de abrir todas las columnas por igual, la red le indicará al árbol cuáles son las 2 o 3 jugadas más lógicas que haría un humano experto, reduciendo el ancho de la búsqueda.
- **Evaluación Inmediata (Valor):** El agente dejará de simular partidas completas hasta el final. El árbol detendrá su búsqueda a una profundidad fija (por ejemplo, 10 turnos adelante) y la red neuronal "adivinará" directamente qué jugador tiene la ventaja, ahorrando miles de operaciones por segundo.

5.2. 2. Persistencia de Memoria mediante el Reúso del Árbol (Tree Reuse)

La arquitectura actual de MCTS borra por completo el árbol de búsqueda al final de cada turno, obligando al agente a empezar desde cero en su siguiente movimiento y descartando miles de simulaciones del futuro que ya se habían calculado. Se propone implementar un sistema de reutilización del subárbol entre turnos. Al guardar el nodo de la acción elegida y emparejarlo con la respuesta real dada por el oponente, el agente puede establecer ese nodo hijo como su nueva raíz. Aplicando una poda inmediata de las ramas hermanas descartadas para proteger la memoria RAM, este enfoque permite que el algoritmo inicie cada turno con un "precalentamiento" estadístico de cientos de visitas previas, acelerando la convergencia del UCB1 y permitiendo alcanzar profundidades de búsqueda inaccesibles para un árbol construido desde cero.