

FVMC agente de Connect 4

Tomás Barrios Guevara
Universidad de la Sabana
Fundamentos de IA

Idea principal

El agente final implementa un enfoque de aprendizaje por refuerzo basado en *First-Visit Monte Carlo* (FVMC) con una tabla de valores Q para pares estado-acción. Durante el entrenamiento, el agente aprende a partir de simulaciones contra un jugador aleatorio o en *self-play*, acumulando retornos descontados y actualizando solamente la primera visita de cada par dentro de cada episodio. Para mejorar la reutilización de experiencia, el estado se representa en forma canónica desde la perspectiva del jugador que mueve, de modo que el conocimiento aprendido puede aprovecharse para ambos colores.

En tiempo de juego, el agente no usa búsqueda online. Primero revisa si tiene una jugada ganadora inmediata; si existe, la toma. Si no, revisa si el rival tiene una victoria inmediata y la bloquea. Cuando no hay una situación táctica directa, elige la acción con mayor valor Q , con desempate favorable a columnas centrales.

Diferencia frente al grupo. Fermín usa MCTS online puro con UCB1: construye un árbol durante el turno y depende de simulaciones online, sin una memoria persistente de valores entre partidas. Rafael usa un enfoque híbrido tipo TBOPI: conserva una memoria global aprendida por self-play, pero además hace mejora online local en cada turno con UCB y rollouts heurísticos. Mi agente se diferencia de ambos porque no realiza búsqueda online durante la partida: toda la mejora se concentra en el entrenamiento offline sobre la tabla Q , y en ejecución solo combina esa memoria aprendida con reglas tácticas inmediatas de ganar/bloquear.

Link al proyecto: <https://github.com/rafaelsava/Connect4RL/tree/Policy-Tomas>

Configuraciones comparadas

Se evaluaron distintas configuraciones de entrenamiento: solo contra jugadores aleatorios, solo *self-play* y combinaciones híbridas. También se comparó entrenar desde cero frente a reutilizar memoria guardando Q -values.

Los resultados muestran que todas las configuraciones obtienen un desempeño alto frente a **Random**, alcanzando entre 95 % y 100 % de victorias.




Figura 1: Desempeño del agente según configuración de entrenamiento frente a **Random** y **Self**.

Validación mínima

La validación se realizó según el tipo de oponente. Frente a **Random**, el agente mostró resultados sólidos en todas las configuraciones. Sin embargo, contra **Self** aparecieron muchos empates debido a que ambos jugadores utilizan la misma política y toman decisiones similares.

Por esta razón, el desempeño contra **Self** refleja más estabilidad de la política que superioridad absoluta.




Figura 2: Desempeño del agente frente a **Random** y a **Self**.

Conclusiones y mejoras futuras

En conclusión, el agente FVMC desarrollado alcanza un rendimiento muy alto frente a un jugador aleatorio bajo todas las configuraciones probadas. No obstante, los experimentos muestran que el desempeño depende tanto del esquema de entrenamiento como del oponente utilizado en la evaluación. En particular, jugar contra una copia exacta de la misma política no es una medida suficiente de progreso, porque el resultado refleja principalmente simetría y estabilidad.

Como trabajo futuro, sería útil incorporar oponentes de evaluación más diversos, estudiar políticas de desempate menos deterministas para reducir simetrías excesivas en *self-play*, ajustar más finamente el parámetro de exploración ϵ , y explorar una versión híbrida que combine la memoria offline del agente con algún mecanismo ligero de mejora online por turno.